



中國人民大學
RENMIN UNIVERSITY OF CHINA

《时间序列分析》

课程论文

战争的代价

——基于俄乌战争死亡人数的时序分析

姓 名: 李昱心

学 号: 2021201655

学 院: 统计学院

专 业: 应用统计学

年 级: 2021 级

指导教师: 王菲菲

摘要

自 2022 年 2 月至今，俄乌战争的炮火从未停歇，已有无数无辜的生命在这场战争中逝去，给交战国甚至世界诸多国家带来巨大损失。在此背景下，进一步预测战争引起的死亡人数显得尤为关键。本文采用官方渠道获取的 2022 年 3 月 25 日至 2024 年 6 月 9 日乌克兰累积死亡人数数据，基于战争前期每天的死亡人数进行时序分析，预测战争最近两个月死亡人数情况。文章综合运用了 ARIMA 模型，条件异方差模型，指数平滑预测模型，多元线性回归，神经网络和循环神经网络模型进行拟合和预测，对比了不同模型的预测表现，得到在此情形下最好的预测模型为 Holt 两参数指数平滑模型，基于分析提出现实建议。

关键词：俄乌战争，时序分析，ARIMA，GARCH，指数平滑预测，机器学习。

目录

1 背景	1
2 数据介绍和分析	1
2.1 数据介绍	1
2.2 数据分析	3
2.2.1 数据检验	3
2.2.2 自相关分析	4
2.2.3 时间序列分解	5
2.2.4 相关性分析	6
3 模型拟合与预测	6
3.1 ARIMA 模型	6
3.2 条件异方差模型	8
3.2.1 ARCH 检验	8
3.2.2 GARCH 模型	9
3.3 指数平滑预测模型	11
3.4 机器学习模型	12
3.4.1 多元线性回归	12
3.4.2 神经网络	13
3.4.3 循环神经网络	13
3.5 预测结果对比分析	14
4 总结与展望	15

1 背景

这是一个和平的年代，这也是一个战乱的年代。

自 2022 年 2 月战争第一炮打响，战火至今仍在延续。2022 年 2 月 24 日，因北约东扩及顿巴斯冲突，普京宣布开展“特别军事行动”，计划对乌克兰进行非军事化和去纳粹化，俄乌冲突正式爆发。冲突发生后，西方国家对俄罗斯施加严厉的制裁，俄罗斯经济遭受震荡，但之后逐步展现出韧性；乌克兰经济则遭到严重破坏，国家预算近四分之一依赖西方援助。同时，冲突还对地区政治与安全、世界经济复苏、全粮食和能源安全、生态环境等诸多方面带来严重负面冲击。

至今，俄乌战争已成为二战结束以来欧洲伤亡人数最多的战争。无数鲜活无辜的生命因此逝去，这让研究战争引起的死亡人数显得十分重要。本文采用官方渠道获取的 2022 年 3 月 25 日至 2024 年 6 月 9 日乌克兰累积死亡人数数据，基于整个战争期间每天的死亡人数进行时序分析，并预测战争持续情况下未来两个月死亡人数情况。除此之外，本文还获取了相同时间区间内乌克兰各类武器装备等军事力量损伤情况，包括战斗机、直升机、无人机、坦克、海军舰艇等军事装备损毁以及野战炮兵、装甲运兵车等军队损伤，共 9 个变量。本文采用若干机器学习模型将上述 9 个变量纳入对每日死亡人数的预测当中，以提高预测准确性。

基于实时更新的数据，模型可以持续预测战争持续情况下未来死亡人数变化，这对乌克兰当局、国际救援组织等政府或组织和被战争影响卷入的全世界民众都有重要警示作用和参考意义。

2 数据介绍和分析

2.1 数据介绍

本文采用的原始数据包括自 2022 年 3 月 25 日至 2024 年 6 月 9 日乌克兰累积死亡人数数据、9 种不同军事力量累积损伤数据，具体变量情况如下表 1 所示。对于其他变量中的缺失数据记零处理，同时剔除异常值。将选择的数据分成训练

和测试集，其中训练集数据从 2022 年 3 月 25 日至 2024 年 4 月 8 日，而测试及数据从 2024 年 4 月 9 日至 2024 年 6 月 9 日。

表 1 原始数据变量说明表

	变量名	解释	最大值
	date	时间	2024/6/9
观察值	personnel_ac	累积死亡人数	518560
其他变量	aircraft	累积战斗机损毁数	357
	helicopter	累积直升机损毁数	326
	tank	累积坦克损毁数	7869
	APC	累积装甲运兵车损毁数	15131
	field artillery	累积野战炮兵损毁数	13593
	MRL	累积火箭发射器损毁数	1097
	drone	累积无人机损毁数	10982
	naval ship	累积海军舰艇损毁数	28
	special equipment	累积专用设备损毁数	2253

本文聚焦于对俄乌战争中乌克兰死亡人数的分析与预测。首先对累积死亡人数建立时序图，如图 1 所示，可以看到随战争时间延续，累积死亡人数持续攀登，符合预期情形。




图 1 累积死亡人数时间序列图

进一步研究每日死亡人数。计算得到每日死亡人数数据，选定每日死亡人数为本文分析和预测的时序数据，对其建立时间序列图，如下图 2 所示。




图 2 每日死亡人数时间序列图

2.2 数据分析

在进行模型拟合和深入分析之前，理解数据的性质和基本构成对于得到精确预测和相关预测至关重要。在本节中，文章将对数据的平稳性和纯随机性进行检验、分解时间序列、进行自相关分析和相关性分析，为此后的模型拟合和预测做好充分准备。

2.2.1 数据检验

平稳性检验

从上图 2 可见，原每日死亡人数时序数据非平稳，进一步进行 ADF 检验进行验证，检验中显示部分模型未通过检验，处于平稳性边界，考虑进行一阶差分序列处理。图 3 为一阶差分后时间序列图，数据基本围绕在 0 值附近波动，已没有了明显的趋势特征。为了进一步确定差分后序列平稳性，对一阶差分后数据进行 ADF 检验，检验结果显示该序列所有 ADF 检验统计量的 P 值均小于显著性水平 ($\alpha=0.05$)，所以可以确认一阶差分后序列实现了平稳。




图 3 每日死亡人数一阶差分后序列时序图

白噪声检验

下面再对一阶差分后序列进行纯随机性检验，检验结果如下表 2 所示。检验结果显示，各阶延迟下 LB 统计量的 P 值均小于小概率水平，这说明差分后序列不是白噪声序列。可以确认一阶差分后序列为平稳非白噪声序列。

表 2 每日死亡人数一阶差分后白噪声检验结果

延迟阶数	χ^2 统计量	P 值
6	127.48	<2.2e-16
12	132.81	<2.2e-16
18	153.3	<2.2e-16

2.2.2 自相关分析

接下来分析一阶差分后序列的自相关性。考察每日死亡人数一阶差分后序列的自相关图偏自相关图，如下图 4 所示。自相关图显示一阶截尾特征，偏自相关图显示二阶拖尾特征，在后续模型选择上将进行进一步考量。




图 4 每日死亡人数一阶差分后序列自相关图和偏自相关图

2.2.3 时间序列分解

洞察时间序列结构的重要方式是对其进行分解，即把序列分解成其各个组成部分。这里使用 STL 加法模型分解序列，得到季节项、趋势项和随机波动项，如下图 5 所示。




图 5 每日死亡人数时序分解图

从图中可以看到，随机波动项并未表现出明显的模式变化，数据季节性被较为恰当地表现，这有利于更好地理解数据。从图中季节性可以看出，战争造成的每日死亡人数在战争进行期间存在季节性效应，这与现实场景中持续的战争会经

历一波接一波较为猛烈的攻势规律相匹配, 在一波激烈交战之后往往迎来一段双方整修的稍平息阶段。这给后续模型拟合和预测带来很大的参考价值。

2.2.4 相关性分析

现在考察其他九个变量与每日死亡人数的相关性。首先将原始数据中九个军事力量累积损伤数进行转换, 得到每日损伤序列, 再分别计算与每日死亡人数的相关系数, 结果如下表 3 所示。

表 3 其他变量与每日死亡人数间相关性

aircraft	helicopter	tank	APC	field artillery	MRL	drone	naval ship	special equipment
-0.396	-0.296	0.016	0.222	0.568	-0.009	0.420	-0.059	0.532

从表中可以看出, 野战炮兵损伤数与死亡人数间呈最高正相关, 其后是专用装备损毁数量和无人机损毁数量。战斗机和直升机损毁数与死亡人数呈显著负相关, 而 MRL、naval ship 损毁数量与死亡人数间相关性很低。

3 模型拟合与预测

经过了前期的分析与准备, 下面将进入对时间序列数据的模型拟合预测。本文采用 ARIMA 模型、条件异方差模型、指数平滑预测模型、机器学习模型分别进行拟合, 并最终对各模型的预测结果进行对比分析。

3.1 ARIMA 模型

在本部分中, 本文利用 R 语言中 auto.arima 函数进行建模。auto.arima 是 R 语言中'forecast'包中广泛使用的函数, 它自动为给定的时间序列数据基于标准选择最佳 ARIMA 模型, 省去了比较 AIC 和 BIC 的繁复工作。

使用 `auto.arima` 函数得到了适合本文数据的 ARIMA(1,1,1)模型, 并对无漂移项和有漂移项模型分别进行显著性检验进行对比, 显著性检验结果如下图 6 所示, 可知两种拟合模型均显著有效。

根据输出的拟合结果, 得到带漂移的 ARIMA(1,1,1)模型为

$$(1 - 0.2096B)(1 - B)x_t = c + (1 + 0.8188B)\varepsilon_t$$

$$\mu = 0.7992; c = (1 - 0.2096)\mu = 0.6317$$

展开上式, 等价表达为:

$$x_t = 0.6317 + 1.2096x_{t-1} - 0.2096x_{t-2} + \varepsilon_t + 0.8188\varepsilon_{t-1} \sim N(0, 16428)$$

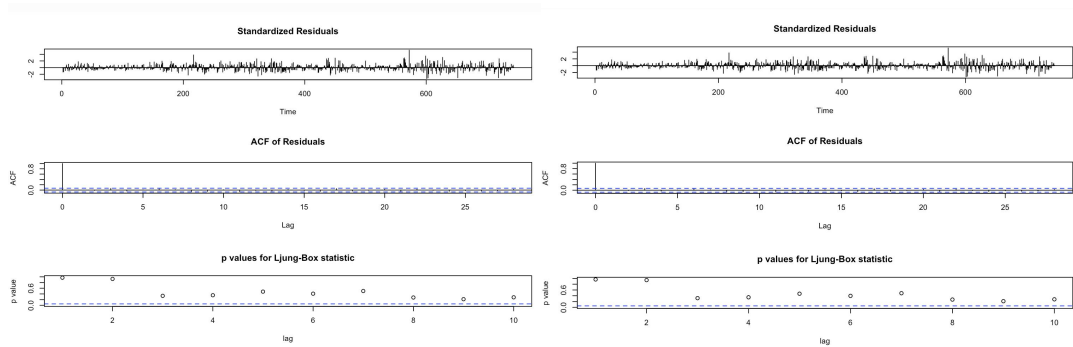


图 6 ARIMA(1,1,1)无漂移项模型(左)有漂移项(右)拟合模型显著性检验

利用 ARIMA(1,1,1)有漂移项模型对测试集中 2024 年 4 月 9 日至 2024 年 6 月 9 日的两个月乌克兰每日死亡人数进行预测, 预测结果如图 7 所示。从预测结果来看, 两月间每日死亡人数将呈缓慢上升趋势。




图 7 ARIMA 模型测试集时间区间每日死亡人数预测结果

3.2 条件异方差模型

当使用 ARIMA 模型拟合非平稳序列时，通常直接默认 $\{\varepsilon_t\}$ 为零均值白噪声序列。但在此之前忽略对方差齐性的检验而直接默认残差序列满足法方差齐性，这可能会严重低估残差的方差，使得参数的显著性检验失去意义，进而使得模型拟合精度受到影响。因此，考虑使用 GARCH 模型进行拟合和预测。

由于 ADF 检验主要适用于方差齐性场合，对异方差序列的平稳性检验可能会有所偏差，这里采用 PP 检验重新对数据进行平稳性检验，检验结果如下表 4 所示。结果显示，延迟 6 阶的 τ 统计量值为 -54.838，检验统计量的 p 值为 0.01，则差分后序列可视为平稳性序列。

表 4 每日死亡人数一阶差分后 PP 平稳性检验

Dickey-Fuller 统计量	延迟阶数	p 值
-54.838	6	0.01

传统的白噪声检验使根据 LB 检验统计量进行的，而 LB 检验统计量是在满足序列方差齐性的假定下构造的。当序列存在异方差属性时，LB 检验统计量不再近似服从卡方分布。因此在异方差可能存在的场合，LB 检验结果自能作为参考信息之一，还要参考自相关系数的大小，如果自相关系数都很小则可以认为序列近似为白噪声序列。由本文数据分析部分检验结果可知，LB 检验的 p 值都很小，序列值之间相关性整体较小。

3.2.1 ARCH 检验

下面进行条件异方差检验，如果序列波动具有异方差属性，则可以考虑拟合 GARCH 模型，本文采用 Portmanteau Q 检验和 LM 检验两种方法进行检验。检验结果如下图 8 所示。Portmanteau Q 检验和 LM 检验的 24 阶延迟都显示该序列显著方差非齐，说明残差平方序列中存在长期相关关系。基于此，本文使用 GARCH 模型提取残差平方序列中蕴含的相关关系。

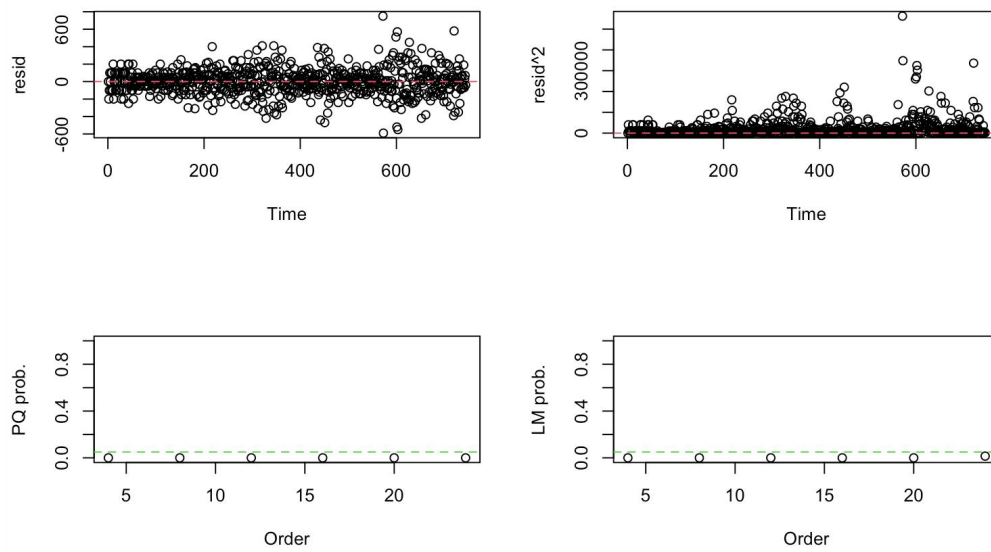


图 8 Q 检验和 LM 检验结果

3.2.2 GARCH 模型

对俄乌战争死亡人数拟合 ARIMA(0, 1, 0)-GARCH(1, 1)模型，基于条件最小二乘估计方法和正态分布假定，得到的拟合模型如下：

$$x_t = x_{t-1} + \varepsilon_t$$

$$\varepsilon_t = \sqrt{h_t} e_t, e_t \sim N(0, 1)$$

$$h_t = 1009.7082 + 0.1102\varepsilon_{t-1}^2 + 0.8523h_{t-1}$$

基于上述模型绘制的条件方差与无条件方差拟合图如下图 9 所示。

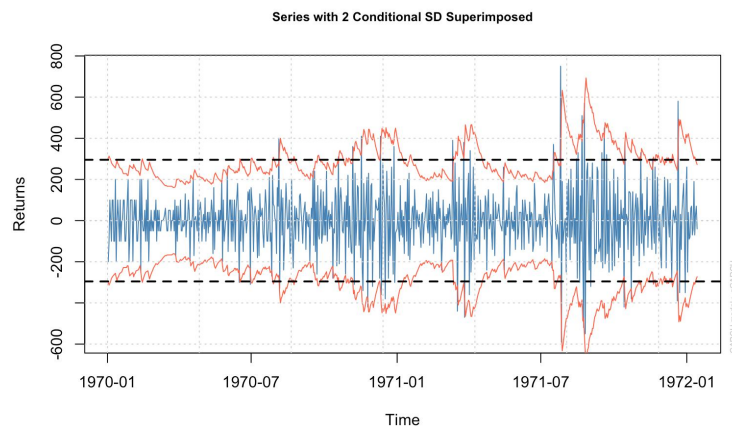


图 9 条件异方差与无条件方差拟合图

从图中可知，当序列大幅波动时，条件异方差置信区间大于无条件方差置信区间；序列小幅波动时，条件异方差置信区间小于无条件方差置信区间，则条件异方差更好地拟合了序列的集群波动特征，更接近与序列真实波动情况。进一步使用此模型进行预测，得到均值预测和方差预测分别如下图 10 和图 11 所示。

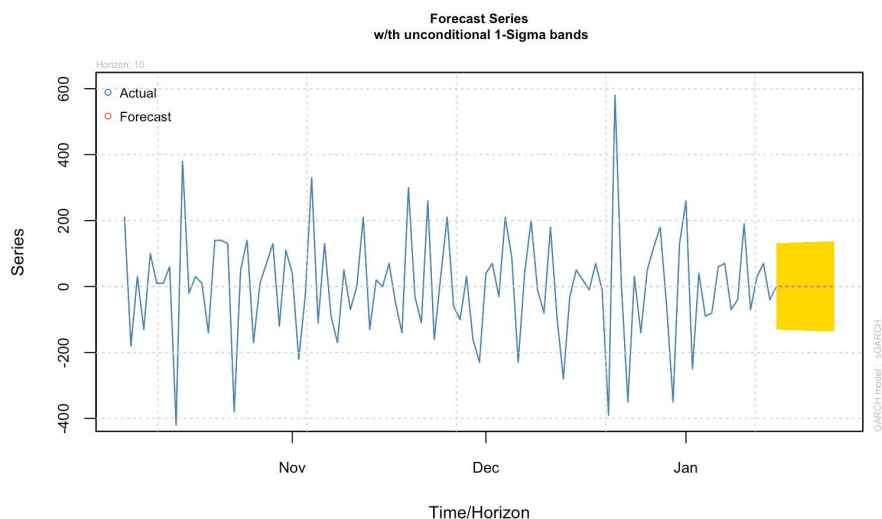


图 10 均值预测图

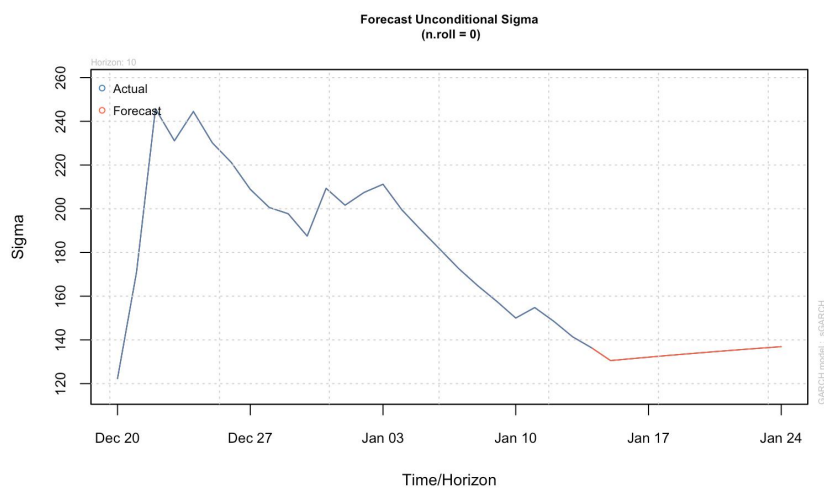


图 11 方差预测图

容易看出，每日死亡人数仍将有一定波动，预测区间的两个月标准差有上升趋势，整体变动幅度不大。

3.3 指数平滑预测模型

在本文数据分析部分中时间序列分解部分得出乌克兰每日死亡人数时间序列呈现一定的季节性和趋势性，下面采用季节性指数平滑模型进行拟合和预测。

从时序图中可以看出，乌克兰每日死亡人数呈现一定的增长趋势，故首先使用 Holt 两参数指数平滑模型进行拟合和预测。预测结果如下图 12 所示。




图 12 Holt 两参数指数平滑模型预测结果

进一步，考虑到数据可能存在着季节效应，且季节效应没有随着时间而增大的趋势，因此考虑 Holt-Winters 三参数指数平滑中的季节加法模型进行拟合和预测。预测结果如下图 13 所示。




图 13 Holt 三参数指数平滑模型预测结果

3.4 机器学习模型

上述传统的时间序列预测模型基于对历史数据的分析，建立统计模型来预测未来的趋势和关系，而这些方法通常是参数化的，需要对底层数据分布做出一定假设。相比而言，机器学习方法通过运用先进算法，能够从时间序列数据中提取更有意义的模式和关系，从而更加准确地预测未来数值和趋势。

在本节中，由原数据中的九个不同的军事力量累积损伤变量得到的各军事力量每日损伤变量将被纳入研究和分析之中。本文采用多元线性回归、神经网络和循环神经网络对测试集时间区间 2024 年 4 月 9 日至 2024 年 6 月 9 日内的乌克兰每日死亡人数进行预测。

3.4.1 多元线性回归

首先采用简单而有效的多元线性回归模型，其结果将被作为后续机器学习模型拟合与预测的基准。将每日死亡人数作为被解释变量，其余九个每日军事力量损伤数量作为解释变量进行建模和预测，对测试集时间区间的预测结果如下图 14 所示。




图 14 多元线性回归预测结果

3.4.2 神经网络

神经网络是一种受生物神经网络启发的机器学习模型，它通过模仿人脑处理信息的方式来识别模式和数据特征。神经网络由大量的节点相互连接构成，这些节点通常被组织成多个层次，包括输入层、一个或多个隐藏层以及输出层。下面将通过神经网络的方法综合其他变量的信息，对每日死亡人数进行预测。相关预测结果如下图 15 所示。




图 15 神经网络预测结果

3.4.3 循环神经网络

循环神经网络（RNNs）是一种适合于序列数据的神经网络架构。与传统的前馈神经网络不同，RNNs 能够处理序列中的动态特征，捕捉时间序列中的动态依赖关系，在时间序列分析中显示出更强大的优势。下面将采用循环神经网络的方法综合其他变量信息，对每日死亡人数进行预测。预测结果如下图 16 所示。



图 16 循环神经网络预测结果

从图中可以看出, 循环神经网络的预测效果并不理想, 这是因为在本案例中, 只有一条序列, 相当于只使用了一天样本训练神经网络, 最终使得循环神经网络学习成了序列均值。

3.5 预测结果对比分析

在进行了多种模型的拟合与预测之后, 我们将所有模型预测结果与测试集真实数据进行对比, 并对比分析各模型的预测结果优劣。对比情况如下图 17 所示。




图 17 各模型预测结果对比

更进一步计算各预测模型的平均偏差并进行对比, 具体数据如下表 5 所示。得到结论: 在此时序分析中预测效果最好的是 Holt 两参数指数平滑模型。

表 5 各模型平均偏差

ARIMA	Holt2	Holt3	Linear Regression	Neutral Network	Recurrent Neutral Network
312.73	184.26	336.88	293.47	255.04	733.47

4 总结与展望

经过多种模型的拟合与预测，从中可以得到在战争持续进行的条件下，乌克兰每日死亡人数仍将继续攀登。若要将此数据预测作为日常监控预测，本文涉及的模型中表现最佳的是 Holt 两参数指数平滑模型。

乌克兰共计人口四千余万人，截止目前已有进六十万人丧生余俄乌战争，不包括大量因战争而受伤或流离失所的难民。这应当引起全世界的警示。国际间争端不断，但无论如何都应共奉珍爱生命，远离战争的全世界人类共同目标。